

اجرای اولین پروژه تشخیص پوسیدگی دندان

در دندانپزشکی، تشخیص و درمان زودهنگام پوسیدگی دندان (که به طور معمول به آن حفره گفته می شود) نقش اساسی در حفظ سلامت دهان و جلوگیری از مشکلات جدی دندان دارد. با پیشرفت‌های یادگیری ماشین و بینایی ماشین، اکنون می توان از این فناوری‌ها برای توسعه سیستم‌های خودکاری استفاده کرد که به شناسایی و طبقه بندی پوسیدگی در تصاویر دهانی کمک می کنند.

هدف ما در این پروژه ساخت یک مدل یادگیری ماشین برای تشخیص پوسیدگی در تصاویر دهانی است. ما از تکنیک‌هایی مانند افزایش داده (data augmentation) و تعدیل (regularization) برای بهبود عملکرد کلی مدل استفاده خواهیم کرد. با استفاده از مجموعه داده‌ای حاوی تصاویر برچسب گذاری شده از اسکن های دهانی، مدل را برای طبقه بندی دقیق تصاویر به عنوان نشان دهنده پوسیدگی یا بدون پوسیدگی آموزش و ارزیابی خواهیم کرد.

برای اجرای پروژه از محیط google colab استفاده شده.

داده‌ها تصاویر از دندان‌ها هستند که شامل دو کلاس پوسیده و بدون پوسیدگی می باشد که در دو پوشه آموزش و تست قرار دارند.

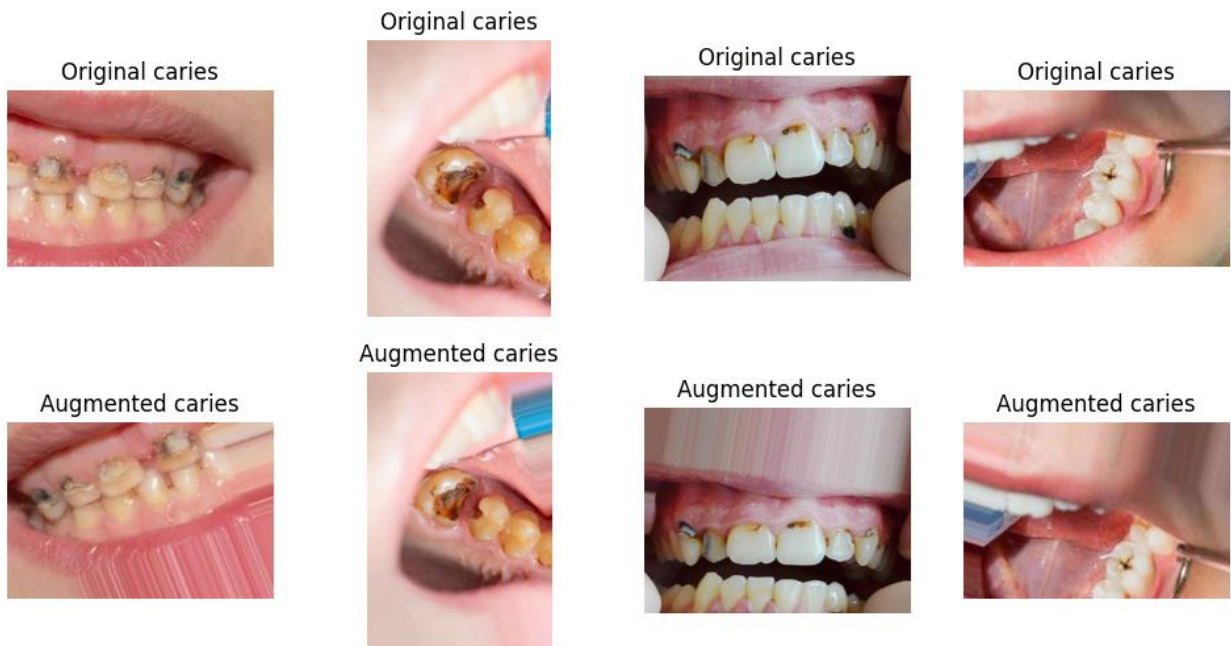
داده‌ها را در همان colab از وبسایت Kaggle دانلود و از حالت فشرده خارج کردیم.

در زیر نمونه‌هایی از تصاویر با پوسیدگی و بدون پوسیدگی را مشاهده می کنیم.





برای اینکه تعداد داده‌ها کم است از تکنیک **data augmentation** استفاده شده. که با اعمال قرینه، چرخش، شیفت، زوم و غیره روی تصاویر، تعداد تصاویر را بیشتر می‌کند.





مدل ارائه شده برای تشخیص پوسیدگی دندان از یک شبکه عصبی کانولوشنی (CNN) با شش لایه تشکیل شده است که هر کدام وظیفه خاص خود را در استخراج ویژگی‌ها، کاهش ابعاد و طبقه بندی تصاویر بر عهده دارند:

۱. لایه Conv2D :

- **وظیفه:** این لایه هسته اصلی عملیات CNN را انجام می دهد که همان عمل کانولوشن است. این لایه ورودی را که یک تصویر ۳ بعدی (224×224 پیکسل با ۳ کانال رنگی RGB) را نشان می دهد، دریافت می کند.

• پارامترها:

- **32:** این تعداد فیلترهایی را که در عمل کانولوشن استفاده می شوند، تعیین می کند. هر فیلتر یاد می گیرد تا ویژگی های خاصی را در تصویر شناسایی کند.
- **(3, 3):** این اندازه هسته فیلتر را مشخص می کند که در این مورد 3×3 مربع است. فیلتر بر روی تصویر حرکت می کند و ضرب عنصر به عنصر با داده های تصویر زیرین انجام می دهد.
- **activation='relu':** این تابع فعال سازی را که به خروجی کانولوشن اعمال می شود، تعریف می کند. ReLU (واحد خطی اصلاح شده) مقادیر منفی را به صفر تنظیم می کند و مقادیر مثبت را بدون تغییر عبور می دهد. این غیرخطی بودن را به مدل معرفی می کند که برای یادگیری الگوهای پیچیده بسیار مهم است.

○ **input_shape=(224, 224, 3)**: این ابعاد مورد انتظار داده های تصویری ورودی را مشخص می کند.

۲. لایه **MaxPooling2D**:

• **وظیفه**: این لایه نمونه برداری کاهش را برای کاهش ابعاد داده های استخراج شده توسط لایه **Conv2D** انجام می دهد. این یک عمل نمونه برداری (معمولاً حداکثر نمونه برداری) را در یک پنجره با اندازه مشخص اعمال می کند.

• پارامترها:

○ **(2, 2)**: این اندازه پنجره نمونه برداری را که در این مورد 2×2 است، تعریف می کند. این لایه حداکثر مقدار را در هر ناحیه 2×2 از خروجی لایه قبلی می گیرد و به طور موثر وضوح فضایی داده ها را کاهش می دهد.

3. لایه **Flatten**:

• **وظیفه**: این لایه خروجی ۲ بعدی از لایه نمونه برداری را به یک بردار ۱ بعدی تبدیل می کند. این امر امکان تغذیه آن را به لایه های کاملاً متصل فراهم می کند.

4. لایه **Dense** (با تنظیم کننده **L2**):

• **وظیفه**: این لایه یک لایه شبکه عصبی **fully connected** است. هر نورون در این لایه به تمام نورون های لایه قبلی متصل است. این لایه یاد می گیرد تا ویژگی های استخراج شده توسط لایه های کانولوشنی را برای طبقه بندی تصویر ترکیب کند.

• پارامترها:

○ **128**: این تعداد نورون های موجود در این لایه را تعیین می کند. هر نورون ترکیبی خاص از ویژگی ها را یاد می گیرد که به تصمیم طبقه بندی کمک می کند.

○ **activation='relu'**: مشابه لایه **Conv2D**، در اینجا از فعال سازی **ReLU** استفاده می شود.

○ **kernel_regularizer=l2(0.01)**: این تنظیم کننده **L2** را به لایه معرفی می کند. تنظیم

کننده **L2** مدل را به دلیل داشتن وزن های بزرگ جریمه می کند، که به جلوگیری از **overfit**

(حفظ کردن داده‌های آموزشی و عدم تعمیم خوب به داده‌های تست) کمک می‌کند. مقدار ۰.۱ قدرت جریمه را کنترل می‌کند.

5. لایه Dropout :


- **وظیفه:** این لایه به طور تصادفی در طول آموزش (در این حالت ۵۰٪) تعدادی از نورون‌ها را حذف می‌کند. این امر مانع از وابستگی بیش از حد مدل به ویژگی‌های خاص می‌شود و آن را تشویق می‌کند تا بازنمایی‌های قوی‌تری از داده‌ها را یاد بگیرد. Dropout به بهبود عملکرد تعمیم مدل کمک می‌کند.

6. لایه Dense (لایه خروجی):


- **وظیفه:** این لایه نهایی فقط یک نورون دارد و از یک تابع فعال سازی سیگموئید استفاده می‌کند. خروجی این نورون احتمال وجود پوسیدگی در تصویر را نشان می‌دهد (سیگموئید مقادیر بین ۰ و ۱ را خروجی می‌دهد، ۰ نشان دهنده عدم وجود پوسیدگی و ۱ وجود پوسیدگی).

بدلیل عدم پیچیده بودن مدل و داده‌های کم، آموزش با ۱۰ اپوک در حدود ۴ دقیقه انجام شد. دقت ۸۸٪ برای داده‌های تست به دست آمد.

در زیر نمودارهای دقت و loss روی داده‌ها آموزش و تست بر حسب اپوک را مشاهده می‌کنید.



Training and Validation Loss



در زیر تعدادی از تصاویر به همراه لیبل‌های واقعی و لیبل‌های پیش‌بینی شده توسط مدل را مشاهده می‌کنیم.



ضعف مدل جایی بوده که تصویر بدون پوسیدگی بوده ولی پوسیدگی تشخیص داده شده، که شاید بدلیل نور کم و سایه افتادن روی تصویر موجب اشتباه مدل شده.

با توسعه موفق یک سیستم خودکار تشخیص پوسیدگی دندان، پتانسیل عظیمی برای بهبود خدمات مراقبت های دندانپزشکی ایجاد می شود. با استفاده از شبکه عصبی کانولوشنی و به کارگیری روش های افزایش داده و تعدیل، توانایی طبقه بندی موثر تصاویر دهانی و شناسایی وجود پوسیدگی دندان را نشان داده ایم. مدل ما در تفکیک بین تصاویر با پوسیدگی و بدون پوسیدگی به دقت قابل توجهی دست یافته است، که قدرت یادگیری ماشین در حوزه سلامت را به نمایش می گذارد.